1 Part One

1.1 1.3.1

$$\vec{a} = \begin{bmatrix} 1\times 2+\frac{1}{2}\times 1-\frac{1}{2}\times 1 \\ 1\times 1-\frac{1}{2}\times 1+\frac{1}{2}\times 3 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

$$\vec{h} = \begin{bmatrix} ReLu(2) \\ ReLu(2) \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

专家1: $\vec{v}_1 = W_{1,1}\vec{h} + \vec{b}_{1,1} = \begin{bmatrix} 2 \\ -2 \end{bmatrix} + \begin{bmatrix} 0 \\ \frac{1}{2} \end{bmatrix} = \begin{bmatrix} 2 \\ -\frac{3}{2} \end{bmatrix}$

$$\vec{u}_1 = \begin{bmatrix} ReLu(2) \\ ReLu(-\frac{3}{2}) \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\vec{f}_1 = W_{2,1}\vec{u}_1 + \vec{b}_{2,1} = \begin{bmatrix} \frac{2}{5} \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ -\frac{1}{2} \end{bmatrix} = \begin{bmatrix} \frac{2}{5} \\ \frac{1}{2} \end{bmatrix}$$

专家2: $\vec{v}_2 = W_{1,2}\vec{h} + \vec{b}_{1,2} = \begin{bmatrix} 2 \\ -2 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$

$$\vec{u}_2 = \begin{bmatrix} ReLu(2) \\ ReLu(-1) \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$\vec{f}_2 = W_{2,2}\vec{u}_2 + \vec{b}_{2,2} = \begin{bmatrix} 0 \\ \frac{2}{5} \end{bmatrix} + \begin{bmatrix} \frac{1}{2} \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{2}{5} \end{bmatrix}$$

$$G\vec{h} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\vec{g} = \text{softmax}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix}$$

$$\vec{r} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} + \frac{1}{2}\begin{bmatrix} \frac{2}{5} \\ \frac{1}{2} \end{bmatrix} + \frac{1}{2}\begin{bmatrix} \frac{1}{2} \\ \frac{2}{5} \end{bmatrix} = \begin{bmatrix} 2.45 \\ 2.45 \end{bmatrix}$$

预测值：
$$C\vec{r} + \vec{b}_c = \begin{bmatrix} 0.49 \\ 0.49 \\ 0.98 \end{bmatrix} + \begin{bmatrix} -0.49 \\ -0.49 \\ -0.98 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\hat{y} = \text{Softmax}\left(\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} \frac{1}{3} \\ \frac{1}{3} \\ \frac{1}{3} \end{bmatrix}$$

损失：
$$L = -\sum_{k=1}^{3} y_k \log \hat{y}_k$$

$$= -(0+1+0)\log\frac{1}{3}$$

$$= \log 3$$

1.2 1.3.2

Softmax的第i个分量为 $\hat{y}_i = \dfrac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$

计j, $J_{i,j} = \dfrac{\partial \hat{y}_i}{\partial z_j} = \dfrac{-e^{z_i} e^{z_j}}{(\sum_{k=1}^{K} e^{z_k})^2}$

$i=j$, $J_{i,i} = \dfrac{\partial \hat{y}_i}{\partial z_i} = \dfrac{-e^{z_i} \cdot e^{z_i}}{(\sum_{k=1}^{K} e^{z_k})^2} + \dfrac{e^{z_i}}{\sum_{k=1}^{K} e^{z_k}} = \dfrac{\sum_{k=1, k\neq i}^{K} e^{z_i} e^{z_k}}{(\sum_{k=1}^{K} e^{z_k})^2}$

记 $S = \sum_{k=1}^{K} e^{z_k}$

则 $J_{i,j} = \begin{cases} -e^{z_i} e^{z_j} / S^2 & i \neq j \\ e^{z_i}(S - e^{z_i}) / S^2 & i = j \end{cases}$

所以 ☆ Softmax的Jacobi矩阵为

$$-\frac{1}{S^2}\begin{bmatrix} e^{z_1}(e^{z_1} - S) & e^{z_1} e^{z_2} & \cdots & e^{z_1} e^{z_K} \\ e^{z_2} e^{z_1} & e^{z_2}(e^{z_2} - S) & \cdots & e^{z_2} e^{z_K} \\ \cdots & & & \cdots \\ e^{z_K} e^{z_1} & e^{z_K} e^{z_2} & \cdots & e^{z_K}(e^{z_K} - S) \end{bmatrix}$$

单样本 $l = -\sum_{i=1}^{K} y_i \log \hat{y}_i$

$$\frac{\partial l}{\partial z_j} = \sum_i \frac{\partial l}{\partial \hat{y}_i} \cdot \frac{\partial \hat{y}_i}{\partial z_j}$$

$$= \sum_{i \neq j} \frac{y_i}{\hat{y}_i} \frac{e^{z_i} e^{z_j}}{S^2} + \frac{y_j}{\hat{y}_j} \cdot \frac{e^{z_j}(e^{z_j} - S)}{S^2}$$

$$= \frac{e^{z_j}}{S} - y_j$$

$$= \hat{y}_j - y_j$$

而 $L = \frac{1}{m} \sum_{i=1}^{m} l^{(i)} = \frac{1}{m}(y_j$

因此小批量平均 $\frac{\partial L}{\partial z_j^{(i)}} = \frac{1}{m}(\hat{y}_j^{(i)} - y_j^{(i)})$

对共享参数，是将各样本的梯度贡献相加后取平均

1.3 1.3.3

求 C 和 b_c 的梯度：

先考虑单样本 记 $\delta_j^{(i)} = \frac{\partial l^{(i)}}{\partial z_j} = \hat{y}_j^{(i)} - y_j^{(i)}$

考虑 C 中的一个元素 C_{ab} $\frac{\partial z_k}{\partial C_{ab}} = \begin{cases} r_b, & k=a \\ 0, & k\neq a \end{cases}$

由链式法则 $\frac{\partial l}{\partial C_{ab}} = \sum_{k=1}^{K} \frac{\partial l}{\partial z_k} \frac{\partial z_k}{\partial C_{ab}} = \delta_a r_b$

因此 $\nabla_C l = \begin{bmatrix} \delta_1 r_1 & \cdots & \delta_1 r_D \\ \vdots & & \vdots \\ \delta_K r_1 & \cdots & \delta_K r_D \end{bmatrix}$

$= \vec{\delta}\,\vec{r}^{\,T}$

考虑 $\vec{b}_c$ 中的一个元素 $b_{c,a}$ $\frac{\partial z_k}{\partial b_{c,a}} = \begin{cases} 1, & k=a \\ 0, & k\neq a \end{cases}$

由链式法则 $\frac{\partial l}{\partial b_{c,a}} = \sum_{k=1}^{K} \frac{\partial l}{\partial z_k} \frac{\partial z_k}{\partial b_{c,a}} = \delta_a$

因此 $\nabla_{\vec{b}_c} l = \vec{\hat{y}} - \vec{y} = \vec{\delta}$

推广到小批量平均可得

$\nabla_C L = \frac{1}{m} \sum_{n=1}^{m} \vec{\delta}^{(n)} \vec{r}^{(n)T} = \frac{1}{m} \sum \begin{bmatrix} \delta_1^{(n)} r_1^{(n)} & \cdots & \delta_1^{(n)} r_D^{(n)} \\ \vdots & & \\ \delta_K^{(n)} r_1^{(n)} & \cdots & \delta_K^{(n)} r_D^{(n)} \end{bmatrix}$

$\nabla_{\vec{b}_c} L = \frac{1}{m} \sum_{n=1}^{m} \left(\vec{\hat{y}}^{(n)} - \vec{y}^{(n)} \right) = \frac{1}{m} \sum_{n=1}^{m} \vec{\delta}^{(n)}$

1

求 $W_{2,e}$ 和 $b_{2,e}$ 的梯度

先考虑单个样本

考虑 $\vec{r}$ 中的一个元素 r_d $\quad \frac{\partial z_k}{\partial r_d} = C_{kd}$

由链式法则 $\quad \frac{\partial l}{\partial r_d} = \sum_{k=1}^{K} \frac{\partial l}{\partial z_k} \frac{\partial z_k}{\partial r_d} = \sum_{k=1}^{K} \delta_k C_{kd}$

记 $\quad \vec{a} = \nabla_{\vec{r}} l = C^T \vec{\delta}$

考虑 $\vec{f}_e$ 的一个分量 $f_{e,d}$ 有 $\quad \frac{\partial r_t}{\partial f_{e,d}} = \begin{cases} g_e, & t=d \\ 0, & t \neq d \end{cases}$

由链式法则 $\quad \frac{\partial l}{\partial f_{e,d}} = \sum_{t=1}^{D} \frac{\partial l}{\partial r_t} \frac{\partial r_t}{\partial f_{e,d}} = a_d g_e$

所以 $\quad \nabla_{f_e} l = g_e C^T \vec{\delta}$

考虑 $W_{2,e}$ 的一个元素 $(W_{2,e})_{ab}$ $\quad \frac{\partial f_{e,d}}{\partial (W_{2,e})_{ab}} = \begin{cases} u_{e,b}, & d=a \\ 0, & d \neq a \end{cases}$

由链式法则 $\quad \frac{\partial l}{\partial (W_{2,e})_{ab}} = \sum_{d=1}^{D} \frac{\partial l}{\partial f_{e,d}} \frac{\partial f_{e,d}}{\partial (W_{2,e})_{ab}} = g_e a_a u_{e,b}$

所以 $\quad \nabla_{W_{2,e}} l = (g_e \vec{a}) \vec{u}_e^T$

考虑 $\vec{b}_{2,e}$ 的一个分量 $\quad \frac{\partial f_{e,d}}{\partial (b_{2,e})_a} = \begin{cases} 1, & d=a \\ 0, & d \neq a \end{cases}$

由链式法则 $\quad \frac{\partial l}{\partial (b_{2,e})_a} = \sum_{d=1}^{D} \frac{\partial l}{\partial f_{e,d}} \frac{\partial f_{e,d}}{\partial (b_{2,e})_a} = g_e a_a$

所以 ~~$\nabla_{b_{2,e}}$~~ $\nabla_{b_{2,e}} l = g_e \vec{a}$

2.

加入小批量平均

$$\nabla_{W_{2,e}} L = \frac{1}{m} \sum_{n=1}^{m} g_e^{(n)} \vec{a}^{(n)} (\vec{u}_e^{(n)})^T$$

$$\nabla_{b_{2,e}} L = \frac{1}{m} \sum_{n=1}^{m} g_e^{(n)} \vec{a}^{(n)}$$

求 $W_{1,e}$ 和 $b_{1,e}$ 的梯度

记 $\bar{r} = \nabla_r l \quad \bar{f}_e = \nabla_{f_e} l$

先求 $\nabla_{u_e} l$：$\frac{\partial f_{e,d}}{\partial u_{e,q}} = (W_{2,e})_{dq}$

所以 $$\frac{\partial l}{\partial u_{e,q}} = \sum_{d=1}^{D} \frac{\partial l}{\partial f_{e,d}} \cdot \frac{\partial f_{e,d}}{\partial u_{e,q}}$$

$$= \sum_{d=1}^{D} (\bar{f}_e)_d (W_{2,e})_{dq}$$

记 $\bar{u}_e = \nabla_{u_e} l = g_e W_{2,e}^T \bar{r}$

再求 $\nabla_{v_e} l$：$\frac{\partial u_{e,q}}{\partial v_{e,q}} = \begin{cases} 1, & v_{e,q} > 0 \\ 0, & v_{e,q} \le 0 \end{cases}$

所以 $$\frac{\partial l}{\partial v_{e,q}} = \frac{\partial l}{\partial u_{e,q}} 1_{\{v_{e,q} > 0\}}$$

记 $M_e = 1_{\{v_e > 0\}}$

则 $\bar{v}_e = \nabla_{v_e} l = \bar{u}_e \odot M_e = (g_e W_{2,e}^T \bar{r}) \odot 1_{\{v_e > 0\}}$

3.

再对 $W_{1,e}$ 求导

$$\frac{\partial v_{e,q}}{\partial (W_{1,e})_{ab}} = \begin{cases} h_b, & q=a \\ 0, & q\neq a \end{cases}$$

$$\frac{\partial \ell}{\partial (W_{1,e})_{ab}} = \sum_{q=1}^{H} \frac{\partial \ell}{\partial v_{e,q}} \cdot \frac{\partial v_{e,q}}{\partial (W_{1,e})_{ab}}$$

$$= (\bar{v}_e)_a h_b$$

所以 $\nabla_{W_{1,e}} \ell = \bar{v}_e h^T$

再对 $b_{1,e}$ 求导

$$\frac{\partial v_{e,q}}{\partial (b_{1,e})_a} = \begin{cases} 1, & q=a \\ 0, & q\neq a \end{cases}$$

$$\frac{\partial \ell}{\partial (b_{1,e})_a} = \frac{\partial \ell}{\partial v_{e,a}} = (\bar{v}_e)_a$$

所以 $\nabla_{b_{1,e}} \ell = \bar{v}_e$

加入小批量平均

$$\nabla_{W_{1,e}} L = \frac{1}{m} \sum_{n=1}^{m} \bar{v}_e^{(n)} (h^{(n)})^T$$

$$\nabla_{b_{1,e}} L = \frac{1}{m} \sum_{n=1}^{m} \bar{v}_e^{(n)}$$

4.

求G的梯度

记 $\rho = Gh \quad g = \text{softmax}(\rho)$

先求g的梯度

$$\frac{\partial r_d}{\partial g_e} = f_{e,d}$$

$$\frac{\partial l}{\partial g_e} = \sum_{d=1}^{D} \frac{\partial l}{\partial r_d} \frac{\partial r_d}{\partial g_e} = f_e^T \bar{r}$$

记 $\beta_e = \frac{\partial l}{\partial g_e} = f_e^T \bar{r}$

$$\beta = [\beta_1, \cdots, \beta_E]^T$$

再求ρ的梯度

$$\frac{\partial g_j}{\partial \rho_e} = g_j (1_{\{j=e\}} - g_e)$$

$$\frac{\partial l}{\partial \rho_e} = \sum_{j=1}^{E} \frac{\partial l}{\partial g_j} \frac{\partial g_j}{\partial \rho_e} = \beta_e g_e - g_e \sum_{j=1}^{E} g_j \beta_j$$

记 $\bar{\rho}_e = \frac{\partial l}{\partial \rho_e} = \beta_e g_e - g_e \sum_{j=1}^{E} g_j \beta_j$

再求G的梯度

$$\frac{\partial \rho_e}{\partial G_{ab}} = \begin{cases} h_b, & e = a \\ 0, & e \neq a \end{cases}$$

$$\frac{\partial l}{\partial G_{ab}} = \sum_{e=1}^{E} \frac{\partial l}{\partial \rho_e} \frac{\partial \rho_e}{\partial G_{ab}} = \bar{\rho}_a h_b$$

5

所以 $\nabla_G \ell = \bar{p} h^T$

加入小批量平均

$$\nabla_G L = \frac{1}{m} \sum_{n=1}^{m} \bar{p}^{(n)} (h^{(n)})^T$$

求 h 的梯度

残差路径：$\left.\frac{\partial r}{\partial h}\right|_{res} = I_D$

$$\nabla_h \ell|_{res} = \bar{r}$$

专家路径：$\left.\frac{\partial Ve,q}{\partial h_d}\right|_{exp} = (W_{1,e})_{qd}$

$$\left.\frac{\partial \ell}{\partial h_d}\right|_{exp\,e} = (W_{1,e}^T \bar{Ve})_d$$

$$\nabla_h \ell|_{exp} = \sum_{e=1}^{E} W_{1,e}^T \bar{Ve}$$

路由器路径：$\frac{\partial Pe}{\partial h_d} = G_{e,d}$

$$\left.\frac{\partial \ell}{\partial h_d}\right|_{rout} = \sum_{e=1}^{E} \bar{Pe} G_{ed}$$

$$\nabla_h \ell|_{rout} = G^T \bar{p}$$

所以 $\nabla_h \ell = \bar{r} + \sum_{e=1}^{E} W_{1,e}^T \bar{Ve} + G^T \bar{p}$

加入小批量平均 $\nabla_{hm} L = \frac{1}{m} \sum_{n=1}^{m} \left[\bar{r}^{(n)} + \sum_{e=1}^{E} W_{1,e}^T \bar{Ve}^{(n)} + G^T \bar{p}^{(n)} \right]$

数值计算 $\frac{\partial L}{\partial G_{1,1}}$：

$$\bar{r} = C^T(\hat{y} - y) = \begin{bmatrix} 1/5 & 0 & 1/5 \\ 0 & 1/5 & 1/5 \end{bmatrix} \begin{bmatrix} 1/3 \\ -2/3 \\ 1/3 \end{bmatrix} = \begin{bmatrix} 2/15 \\ -1/15 \end{bmatrix}$$

$$\beta_1 = f_1^T \bar{r} = \frac{1}{50}$$

$$\beta_2 = f_2^T \bar{r} = \frac{1}{25}$$

$$\frac{\partial L}{\partial p_1} = g_1(\beta_1 - g_1\beta_1 - g_2\beta_2) = -\frac{1}{200}$$

$$\frac{\partial L}{\partial G_{1,1}} = \frac{\partial L}{\partial p_1} h_1 = -\frac{1}{100}$$

1

1.4 1.3.4

由于 $a_1 = a_2 = z > 0$，所以 ReLu 导数为 1，所以

$$\frac{\partial L}{\partial a_1} = \frac{349}{2400} \quad \frac{\partial L}{\partial a_2} = -\frac{173}{2400}$$

分别记为 $\bar{a}_1$ $\bar{a}_2$

由
$$\frac{\partial a_j}{\partial q_t} = s_{j+t-1}$$

$$\frac{\partial L}{\partial q_t} = \sum_{j=1}^{2} \frac{\partial L}{\partial a_j} \frac{\partial a_j}{\partial q_t}$$

得
$$\frac{\partial L}{\partial q_t} = \bar{a}_1 s_t + \bar{a}_2 s_{t+1}$$

所以 $\frac{\partial L}{\partial q_1} = \frac{525}{2400}$ $\frac{\partial L}{\partial q_2} = \frac{522}{2400}$ $\frac{\partial L}{\partial q_3} = \frac{-868}{2400}$

所以 $\nabla_q L = \frac{1}{2400}\begin{bmatrix} 525 \\ 522 \\ -868 \end{bmatrix}$

对 s_2 的梯度 $\frac{\partial L}{\partial s_2} = \bar{a}_1 q_2 + \bar{a}_2 q_1$

$$= \frac{1}{1600}$$

卷积核更新

$$q^{new} = q^{old} - \eta \nabla_q L$$

$$= \begin{bmatrix} 1 \\ 0.5 \\ 0.5 \end{bmatrix} - 0.1 \begin{bmatrix} 7/32 \\ 87/400 \\ -217/600 \end{bmatrix}$$

$$= \begin{bmatrix} 313/320 \\ 1913/14000 \\ 3217/6000 \end{bmatrix}$$

$$= \begin{bmatrix} 0.9781 \\ 0.4783 \\ 0.536167 \end{bmatrix}$$

2

2 Part Two

2.1 2.3.1

实现前向和反向传播，请见 `NumPy/model.py`. 复现第一部分的损失为 $\log 3 = 1.0986122886681098$，与第一部分手动计算的结果一致，且也支持提供的三专家 Top-2 情形。

2.2 2.3.2

运行 `python NumPy/run.py --check`，所报告的每类参数和输入的误差见表 1。

表 1: 各类参数和输入的最大归一化梯度误差。正常梯度均低于 10^{-5}；末行为故意遗漏路径的错误梯度对照。

参数/输入	两专家数值例	三专家 Top-2
W_1	1.40×10^{-11}	1.37×10^{-10}
b_1	1.08×10^{-10}	1.23×10^{-10}
W_2	4.08×10^{-11}	1.17×10^{-10}
b_2	9.35×10^{-11}	1.00×10^{-10}
G	6.08×10^{-11}	8.21×10^{-11}
C	4.27×10^{-11}	1.14×10^{-10}
b_c	6.44×10^{-11}	1.60×10^{-10}
输入	4.14×10^{-11}	1.08×10^{-10}
错误输入梯度（对照）	0.1333	0.2797

经诊断所提供的错误输入梯度变体，判断是从正确输入梯度中减去了 ΔC，遗漏了恒等残差路径。

2.3 2.3.3

绘制的损失曲线如图 1所示，三个预测请见表 2。

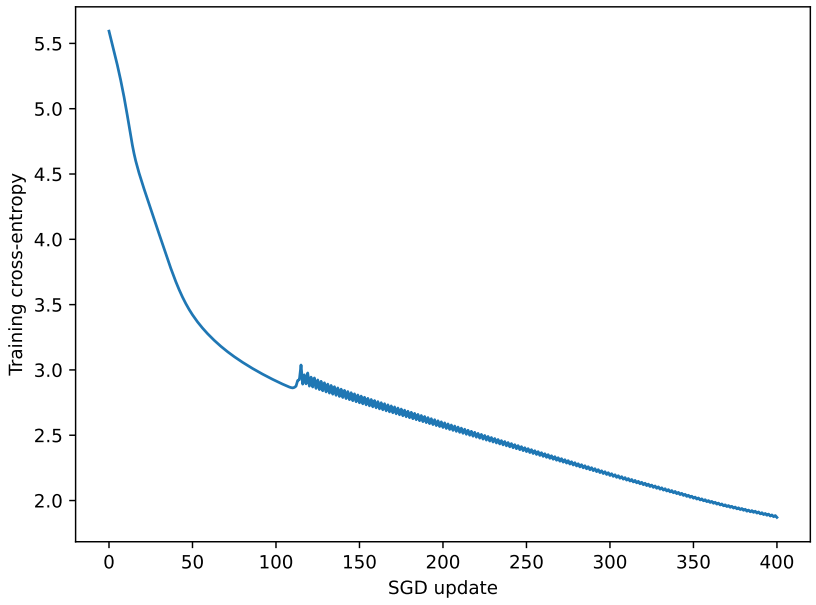


图 1: 固定 128 样本批次上的训练交叉熵，使用学习率 0.2 进行 400 次 SGD 更新。

表 2: 脚本固定的三个预测示例。上下文按可读字符展示，括号内为目标或预测的字节值，空格显式标注。

样本索引	上下文	真实下一字节	预测下一字节
0	`tle'`	`s`（115）	空格（32）
64	`est=`	`a`（97）	`e`（101）
1	`u as`	空格（32）	空格（32）

从预测结果可以看出，预测并非完全正确。

3 Part Three

3.1 3.4.1

专家前向计算、路由器和所选 token 的分发均已补全，请见 `MoE/model.py`.
三种配置的训练/验证曲线如图 2所示，测试指标如表 3所示

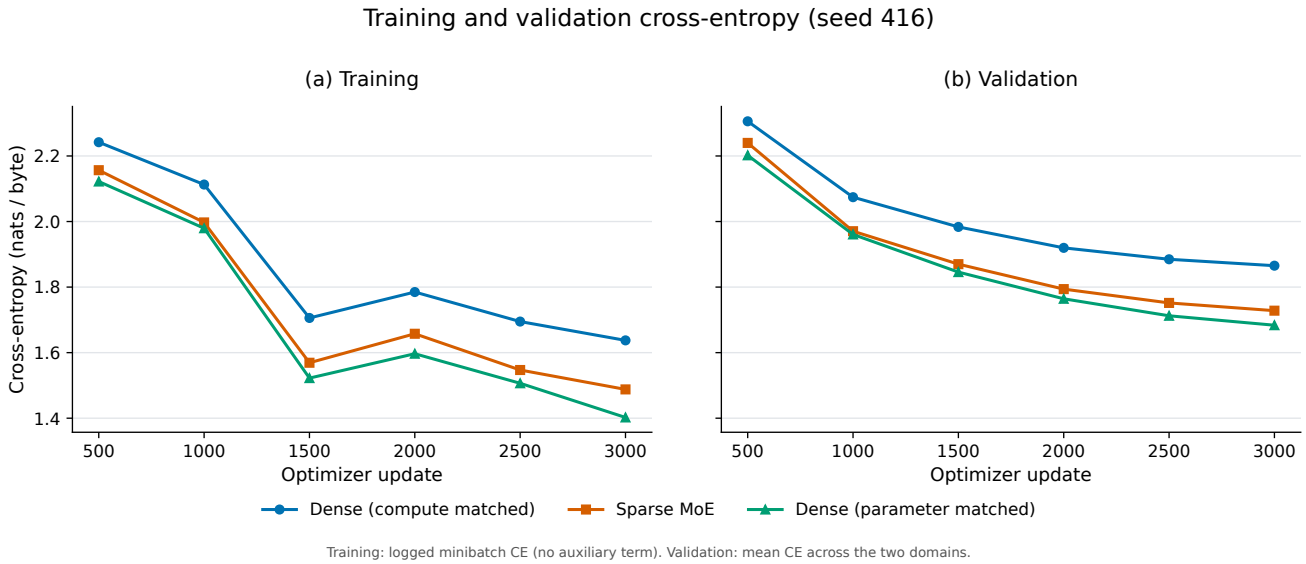


图 2: 三种配置的训练与验证交叉熵曲线（随机种子为 416）。

表 3: 三种配置的测试指标。平均 CE 为文本域与代码域 CE 的等权平均，PPL 为平均 CE 的指数。

配置	文本 CE	代码 CE	平均 CE	PPL
Dense（计算量匹配）	1.9787	1.7960	1.8874	6.6020
MoE	1.9238	1.6505	1.7872	5.9725
Dense（参数量匹配）	1.8958	1.6058	1.7508	5.7591

3.2 3.4.2

质量、总参数量、每 token 的 MAC 次数以及完整批次前向延迟的比较见表 4

表 4: 三种配置的质量、容量与计算成本比较。延迟为 NVIDIA GeForce RTX 4060 Laptop GPU 上完整批次（$B = 32, T = 64$）前向耗时的中位数，包含分发开销。

配置	测试 CE	测试 PPL	总参数量	MAC/token	延迟（ms/批）
Dense（计算量匹配）	1.8874	6.6020	139,024	133,120	0.3105
MoE	1.7872	5.9725	603,264	133,120	3.2826
Dense（参数量匹配）	1.7508	5.7591	601,360	591,872	0.6872

专家使用情况见图 3

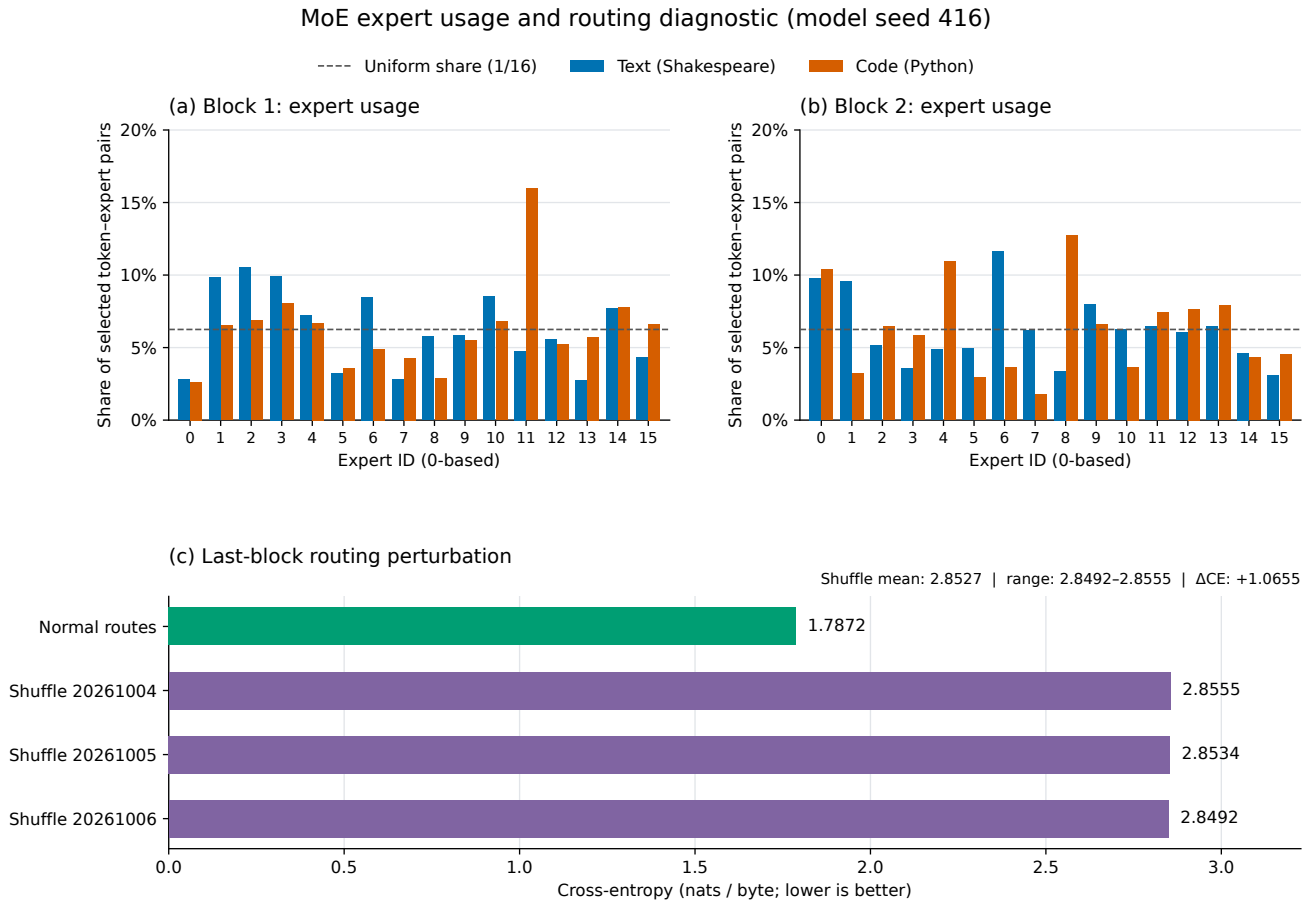


图 3: 两个 MoE 块的专家使用比例，以及正常路由与三个固定种子下最后一层路由扰动的诊断 CE（模型随机种子为 416）。

容量与预测质量 先比较 MoE 与计算量匹配的 Dense，可以发现二者都是 133,120MAC/token，MoE 的总参数约为 Dense 的 4.34 倍，测试 PPL 下降约 9.53%，文本和代码域 CE 均下降，其中代码域改善更大。因此在相同理论矩阵计算预算下，MoE 提供了更大的参数容量，并在本次实验中得到了更好的预测质量。

再比较 MoE 与参数量匹配的 Dense，二者的参数量相差仅 0.32%，Dense 的 PPL 为 5.7591，优于 MoE 的 5.9725，但是 MoE 的 MAC 减少约 77.5%，因此可以看出 MoE 用更少的计算取得了接近的质量，但是在本次实验中参数匹配的 Dense 效果仍然更好。

理论计算与实际延迟 从同一设备的实验可以看出，

- 计算量匹配 Dense: 0.3105ms/批
- MoE: 3.2826ms/批
- 参数量匹配 Dense: 0.6872ms/批

可以看出 MoE 分别慢了 10.57 倍和 4.78 倍，这可能与路由、筛选 token 等步骤需要额外操作有关，但是没有进行实验验证。不过可以从中看出，MAC 可以衡量理论矩阵运算量，但是不能单独预测实际延迟。

路由扰动 从数据中可以看出：

- 正常 CE: 1.7872
- 扰动后平均诊断 CE: 2.8527

可以从中看出，即使专家负载不变，扰乱原有的 token-路由匹配也会损害预测。但是由于扰动同时影响专家身份和权重，无法区分二者作用。

专家使用情况 从图中可以看出，两层的 16 个专家均有使用，但是比例并不均匀，且文本域和代码域的专家使用分布不同，例如第一层的专家 11, 代码域使用比例为 15.95%, 而文本域约为 4.76%，这说明路由存在数据域相关的偏好，到那时还不足以证明某专家已经具备语义能力或专门负责 Python.

3.3 3.4.3

研究问题。在最后一个 MoE 块选中的两个专家完全相同时，学习到的融合权重是否比等权混合更有利于预测？前一小题同时扰动专家身份与权重，本实验仅隔离融合权重的作用。

实验设计。使用种子 416 训练所得的验证最优检查点，不重新训练，不改变任何模型参数、第一块或最后一块的专家选择。仅将最后一块选中专家的权重替换为

$$g_e^{(\alpha)} = \alpha g_e + (1-\alpha)/2, \qquad \alpha \in \{0, 0.5, 1\}.$$

其中 $\alpha = 1$ 是原模型对照，$\alpha = 0$ 为等权，0.5 为中间设置。三个取值在评估前固定。三组均在 Orin GPU 上，按原协议评估完整测试数据块（$B = 32, T = 64$），分别计算两域 CE 并等权平均，再取指数得到 PPL。每条序列独立推理。本机重新计算正常对照，避免跨设备比较。

控制检查。原模型与 $\alpha = 1$ 包装后的探针输出完全一致。完整测试的 1,291,008 个位置在三组中的专家编号指纹相同，各层专家使用次数及评估目标数也一致。参数量和矩阵 MAC 不变，改变的只有最后一块的融合权重。

表 5: 固定最后一块专家选择时，不同融合权重的测试结果。

α 与设置	文本 CE	代码 CE	平均 CE	PPL
1（学习权重）	1.9238	1.6505	1.7872	5.9726
0.5（中间设置）	1.9400	1.6798	1.8099	6.1096
0（等权）	2.0432	1.7875	1.9153	6.7892

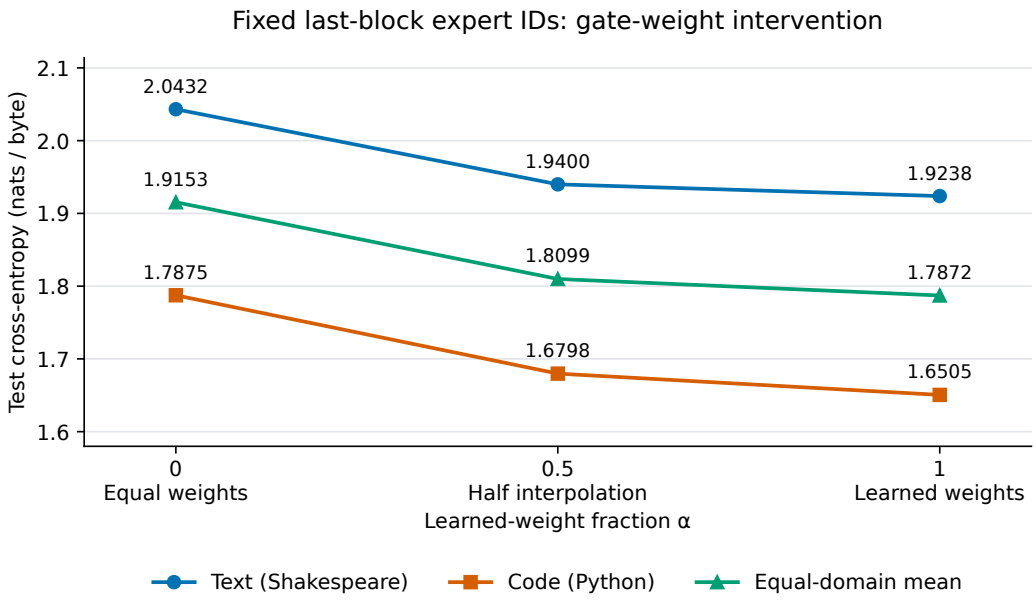


图 4: 固定专家编号，逐步从等权恢复到学习权重时的测试交叉熵。

结果与解释。如表 5及图 4，在三个取值上，两域 CE 均随 α 增大而下降。等权相对学习权重使平均 CE 增加 0.1282，PPL 增加 13.67%；中间设置介于两者之间。即使选中的专家完全相同，等权也不能复现原模型质量，表明该检查点中学习权重在专家选择之外提供了额外价值。

局限。仅考察一个训练种子的最后一块，且模型原本与学习权重共同训练；推理时替换权重会造成分布变化。结果不能说明从头进行等权训练一定更差，也不能推断所有层、所有插值取值或其他模型均有相同表现。

复现。在仓库根目录运行以下命令，可重新评估、保存日志并绘图。

```
python scripts/explore_gate_weights.py --device cuda
```

AI Use Statement（本探索部分） 本探索使用 OpenAI Codex 辅助设计对照实验、编写评估与绘图脚本，并整理分析文字。所有数值均由脚本读取现有检查点并实际评估得到，未编造实验结果。验证包括原模型输出一致性、全部测试位置的专家编号指纹，以及各层专家使用次数与评估目标数一致性。本探索按题目允许 AI 协助的范围开展，本声明仅覆盖该探索部分，最终提交内容与责任由提交者承担。